

Kolibri CRM — Matriz de Costos de Modelos IA

Entregable 3 · Ecosistema de Automatización IA Autónomo · Entrega Final — Coderhouse AI Automation

Este documento compara el costo de los modelos de IA disponibles para la etapa de generación de contenido del flujo (nodo *Message a Model*), justifica la elección de **Claude Sonnet 5** como modelo de producción, y proyecta el costo mensual del ecosistema a distintos volúmenes de uso. Los precios corresponden a las tarifas públicas de cada proveedor vigentes a septiembre de 2026 (ver fuentes al final).

1. Comparativa de precios por proveedor (por millón de tokens)

Proveedor	Modelo	Input (USD/1M tok)	Output (USD/1M tok)	Perfil
Anthropic	Claude Haiku 4.5	\$1.00	\$5.00	Rápido / económico
Anthropic	Claude Sonnet 5 ★	\$2.00	\$10.00	Balance calidad/costo (elegido)
Anthropic	Claude Opus 5	\$5.00	\$25.00	Máxima calidad de razonamiento
Anthropic	Claude Fable 5.1	\$10.00	\$50.00	Premium / creatividad
OpenAI	GPT-4o	\$2.50	\$10.00	Equivalente directo a Sonnet 5
OpenAI	GPT-5.6 Terra	\$2.00	\$12.00	Gama media 2026
OpenAI	GPT-6 Astra	\$10.00	\$50.00	Flagship más nuevo
Google	Gemini 2.5 Flash	\$0.15	\$1.25	Más económico del mercado
Google	Gemini 2.5 Pro	\$2.00	\$12.00	Equivalente a gama Sonnet

★ Modelo configurado actualmente en el nodo *Message a Model* del flujo (credencial "Anthropic account", claude-sonnet-5). Cache hits facturan al 10% del precio de input en los tres proveedores, y las Batch APIs reducen el costo total a la mitad cuando el caso de uso no requiere respuesta en tiempo real.

2. Estimación de consumo por ejecución

Cada ejecución del flujo llama a Claude API una sola vez, con el contexto RAG (Base RAG, 6 fragmentos) más la idea semilla incrustados en el prompt, y devuelve una pieza de contenido corta (post de LinkedIn o similar). Estimación basada en las ejecuciones de prueba reales del Entregable de testing:

Componente	Tokens aprox.	Detalle
Input — contexto RAG + prompt + idea semilla	~1.200 tokens	6 fragmentos de Base RAG + instrucciones del sistema
Output — contenido generado	~300 tokens	Post de LinkedIn de largo estándar
Total por ejecución	~1.500 tokens	—

2.1 Costo por ejecución con Claude Sonnet 5

Input: $1.200 / 1.000.000 \times \$2.00 = \$0.0024$ | Output: $300 / 1.000.000 \times \$10.00 = \0.0030 → **Costo por pieza de contenido $\approx$ \$0.0054 USD** (menos de un centavo de dólar).

3. Proyección de costo mensual por volumen

Proyección a tres escenarios de volumen (piezas de contenido generadas por mes), comparando el modelo elegido contra las alternativas más económica y más premium de cada proveedor.

Modelo	20 piezas/mes	100 piezas/mes	500 piezas/mes
Claude Haiku 4.5	\$0.05	\$0.27	\$1.35
Claude Sonnet 5 ★ (elegido)	\$0.11	\$0.54	\$2.70
Claude Opus 5	\$0.27	\$1.35	\$6.75
GPT-4o (OpenAI)	\$0.11	\$0.55	\$2.75
Gemini 2.5 Flash (Google)	\$0.01	\$0.04	\$0.21

Supuesto de volumen: 20 piezas/mes equivale al ritmo actual estimado para Kolibri CRM (~5 por semana); 100 y 500 modelan un escenario de escalado a agencia (Blue Sheep Digital atendiendo múltiples cuentas). En los tres escenarios el costo de IA es marginal frente al valor generado (horas de trabajo humano ahorradas).

4. Justificación del modelo elegido

- **Costo irrelevante a esta escala:** incluso en el escenario de 500 piezas/mes, Sonnet 5 cuesta menos de \$3 USD mensuales — no es el factor limitante del sistema.
- **Calidad de escritura:** Sonnet 5 mantiene coherencia de tono y sigue instrucciones de formato (devolver únicamente el texto final, sin explicaciones) de forma más consistente que Haiku en las pruebas realizadas.
- **Contexto largo sin sobre costo:** Sonnet 5 incluye ventana de 1M tokens a tarifa plana, lo que deja margen para crecer la Base RAG sin rediseñar el flujo.
- **Camino de escalado ya definido:** si el volumen crece agresivamente (varios miles de piezas/mes), migrar el nodo a Haiku 4.5 o a Gemini 2.5 Flash es un cambio de un solo campo en el nodo *Message a Model*, sin tocar el resto del flujo.

- **Human-in-the-loop como control de calidad real:** como toda pieza pasa por aprobación humana vía Gmail antes de publicarse, el costo de una eventual respuesta de menor calidad de un modelo más barato es bajo — refuerza que HITL es la salvaguarda, no el modelo en sí.

Fuentes de precios (consultadas en septiembre de 2026):

Anthropic — cloudzero.com/blog/claude-pricing · finout.io/blog/anthropic-api-pricing | OpenAI — cloudzero.com/blog/openai-pricing · morphllm.com/openai-api-pricing | Google — ai.google.dev/gemini-api/docs/pricing · cloudzero.com/blog/gemini-pricing

Kolibri CRM · Caso de estudio — Coderhouse AI Automation · Entrega Final · Sam Rodriguez